

# Limpieza inicial de datasets

En este notebook se realiza la preparación básica de los datasets antes de su transformación al modelo documental.

El objetivo no es limpiar completamente los datos ni eliminar valores nulos, sino normalizar su formato para permitir su posterior integración en MongoDB.

Se aplican las siguientes transformaciones:

- Eliminación de espacios en blanco en columnas de texto
- Conversión de fechas a tipo datetime
- Normalización de tipos de datos
- Exportación a versión limpia (clean)

```
In [1]: import pandas as pd

pd.set_option("display.max_columns", None)
pd.set_option("display.max_colwidth", None)
pd.set_option('display.max_rows', None)
```

## Problemas detectados en los datasets originales

Durante la exploración inicial se observaron varios problemas comunes en datos procedentes de sistemas administrativos:

- Espacios en blanco al inicio o final de los textos
- Fechas almacenadas como cadenas de texto
- Columnas con tipos mezclados (número y texto)
- Valores vacíos representados de distintas formas

Estos problemas no impiden la lectura del CSV, pero sí pueden provocar:

- Errores al generar JSON

- Tipos inconsistentes en MongoDB
- Resultados incorrectos en agregaciones

Por ello se aplica una normalización ligera previa al modelado.

```
In [2]: def limpiar_strings(df):
        """Elimina espacios en blanco al inicio y final de todos los textos"""
        for col in df.select_dtypes(include=["object", "string"]).columns:
            df[col] = df[col].astype("string").str.strip()
            df[col] = df[col].replace("", pd.NA)
        return df

def convertir_fechas(df):
    """Convierte automáticamente columnas con fecha"""
    posibles = [c for c in df.columns if "fecha" in c.lower() or "fx_" in c.lower()]

    for col in posibles:
        try:
            df[col] = pd.to_datetime(df[col], errors="coerce", dayfirst=True)
        except:
            pass
    return df

def normalizar_tipos(df):
    """Evita tipos mezclados que rompen Mongo"""
    for col in df.columns:
        if df[col].dtype == "object":
            # intenta convertir a numérico si parece número
            convertido = pd.to_numeric(df[col], errors="ignore")
            df[col] = convertido
    return df

def limpiar_dataset(path):
    df = pd.read_csv(path, sep=';', low_memory=False)

    print("Cargando:", path)
    print("Shape original:", df.shape)
```

```
df = limpiar_strings(df)
df = convertir_fechas(df)
df = normalizar_tipos(df)

print("Limpieza completada\n")
return df
```

## Carga y limpieza de los datasets

Cada fichero se carga individualmente y se somete al mismo proceso de normalización para garantizar coherencia entre todos los conjuntos de datos.

```
In [3]: df_terrazas = limpiar_dataset("../data/raw/terrazas202312.csv")
df_locales = limpiar_dataset("../data/raw/locales202312.csv")
df_licencias = limpiar_dataset("../data/raw/licencias202312.csv")
df_actividad = limpiar_dataset("../data/raw/actividadeconomica202312.csv")
```

```
Cargando: ../data/raw/terrazas202312.csv
Shape original: (6788, 61)
Limpieza completada
```

```
Cargando: ../data/raw/locales202312.csv
Shape original: (151162, 48)
Limpieza completada
```

```
Cargando: ../data/raw/licencias202312.csv
Shape original: (150829, 49)
Limpieza completada
```

```
Cargando: ../data/raw/actividadeconomica202312.csv
Shape original: (169559, 49)
Limpieza completada
```

## Verificación de la limpieza

Se inspecciona la estructura resultante para comprobar:

- Tipos de datos correctos
- Ausencia de espacios residuales
- Conversión adecuada de fechas

In [4]: `df_terrazas.head()`

Out[4]:

	id_terraza	id_local	id_distrito_local	desc_distrito_local	id_barrio_local	desc_barrio_local	id_ndp_edificio	id_clase_ndp_edificio	id_via
--	------------	----------	-------------------	---------------------	-----------------	-------------------	-----------------	-----------------------	--------

0	33	270403150	4	SALAMANCA	404	GUINDALERA	11018870	1	
1	1168	80000291	8	FUENCARRAL-EL PARDO	806	VALVERDE	20057165	1	
2	42	40002970	4	SALAMANCA	403	FUENTE DEL BERRO	11016907	1	
3	1176	40002488	4	SALAMANCA	406	CASTELLANA	11019901	1	
4	56	170000773	17	VILLAVERDE	1704	LOS ROSALES	11126803	1	



In [5]: `df_terrazas.info()`

```

<class 'pandas.DataFrame'>
RangeIndex: 6788 entries, 0 to 6787
Data columns (total 61 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id_terraza                           6788 non-null   int64
1   id_local                             6788 non-null   int64
2   id_distrito_local                    6788 non-null   int64
3   desc_distrito_local                  6788 non-null   string
4   id_barrio_local                      6788 non-null   int64
5   desc_barrio_local                    6788 non-null   string
6   id_ndp_edificio                     6788 non-null   int64
7   id_clase_ndp_edificio                6788 non-null   int64
8   id_vial_edificio                     6788 non-null   int64
9   clase_vial_edificio                  6788 non-null   string
10  desc_vial_edificio                   6788 non-null   string
11  nom_edificio                         6788 non-null   string
12  num_edificio                         6788 non-null   int64
13  Cod_Postal                           6788 non-null   int64
14  coordenada_x_local                   6788 non-null   float64
15  coordenada_y_local                   6788 non-null   float64
16  id_tipo_acceso_local                 6788 non-null   int64
17  desc_tipo_acceso_local                6788 non-null   string
18  id_situacion_local                   6788 non-null   int64
19  desc_situacion_local                 6788 non-null   string
20  secuencial_local_PC                  6788 non-null   int64
21  Escalera                             123 non-null    string
22  id_planta_agrupado                   6784 non-null   string
23  id_local_agrupado                    5524 non-null   string
24  coordenada_x_agrupacion              105 non-null    float64
25  coordenada_y_agrupacion              105 non-null    float64
26  rotulo                               6788 non-null   string
27  id_periodo_terraza                   6788 non-null   int64
28  desc_periodo_terraza                 6788 non-null   string
29  id_situacion_terraza                 6788 non-null   int64
30  desc_situacion_terraza               6788 non-null   string
31  Superficie_ES                        6788 non-null   float64
32  Superficie_RA                        5610 non-null   float64
33  Fecha_confir_ult_decreto_resol       6788 non-null   datetime64[us]
34  id_ndp_terraza                       6788 non-null   int64
35  id_clase_ndp_terraza                 6788 non-null   int64

```

```

36 id_vial                6788 non-null    int64
37 desc_clase             6788 non-null    string
38 desc_nombre            6788 non-null    string
39 nom_terraza            6788 non-null    string
40 num_terraza            6788 non-null    int64
41 cal_terraza            581 non-null     string
42 desc_ubicacion_terraza 6788 non-null    string
43 hora_ini_LJ_es         6788 non-null    string
44 hora_fin_LJ_es         6788 non-null    string
45 hora_ini_LJ_ra         5610 non-null    string
46 hora_fin_LJ_ra         5610 non-null    string
47 hora_ini_VS_es         6788 non-null    string
48 hora_fin_VS_es         6788 non-null    string
49 hora_ini_VS_ra         5610 non-null    string
50 hora_fin_VS_ra         5610 non-null    string
51 mesas_aux_es           6788 non-null    int64
52 mesas_aux_ra           6549 non-null    float64
53 mesas_es               6788 non-null    int64
54 mesas_ra               6549 non-null    float64
55 sillas_es              6788 non-null    int64
56 sillas_ra              6549 non-null    float64
57 cal_edificio           523 non-null     string
58 fx_carga               6788 non-null    datetime64[us]
59 fx_datos_ini           6788 non-null    datetime64[us]
60 fx_datos_fin           6788 non-null    datetime64[us]

```

dtypes: datetime64[us](4), float64(9), int64(21), string(27)

memory usage: 3.2 MB

## Exportación de datasets normalizados

Los datasets resultantes se guardan en una versión *clean*.

Estos archivos no contienen cambios estructurales ni pérdida de información; únicamente se ha normalizado su formato para permitir su posterior transformación al modelo documental y su inserción en MongoDB.

```

In [6]: df_terrazas.to_csv("../data/cleaned/terrazas_clean.csv", index=False)
df_locales.to_csv("../data/cleaned/locales_clean.csv", index=False)
df_licencias.to_csv("../data/cleaned/licencias_clean.csv", index=False)

```

```
df_actividad.to_csv("../data/cleaned/actividad_clean.csv", index=False)  
print("Datasets limpios guardados en /data/clean")
```

Datasets limpios guardados en /data/clean